Curso Libre de Configuración 2: Análisis de Datos
Tarea 3: Introducción a series de tiempo

< Jose Gregorio Coronel Colombo > – jcoronel@unis.edu.gt

Fecha de entrega: 25 de octubre 2026, 11:59PM

Uso de inteligencia artificial

En este trabajo se usó inteligencia artificial como apoyo para escribir varios de los códigos en Python a partir de las fórmulas y reglas del enunciado, para hacer algunas de las gráficas y dar formato a las tablas, para resolver dudas de pandas y statsmodels, y para investigar temas que no quedaban claros con los libros, como el sesgo del estimador OLS de ϕ, por qué el modelo de aerolínea extrapola una pendiente y cómo se calcula el AUC con rangos. También se usó para ordenar la redacción del documento a partir de los resultados. La semilla, qué líneas cuentan como venta, el orden de las reglas de limpieza y las derivaciones del inciso 0.1 se hicieron sin IA, y los números del texto se revisaron contra la salida de los scripts. Al inicio de cada archivo `.py` se indica para qué se usó la IA en ese archivo.

Reproducibilidad y semillas

Todo sale del archivo original `datos/Online Retail.xlsx`, que va incluido en el repositorio tal como se descarga de UCI. Desde la carpeta `codigo/`, los cuatro scripts

```
python3 generar_resultados_procesos_simulados.py
python3 generar_resultados_limpieza_calendario.py
python3 generar_resultados_series_pronostico.py
python3 generar_resultados_rfm.py
```

vuelven a producir todas las figuras y todas las tablas de este informe. Cada script guarda sus figuras en `figuras/` e imprime las tablas ya escritas en LaTeX, que son las que aparecen incrustadas en este documento. La función `limpiar` está sola en `limpieza_datos.py`, como pide el enunciado.

La semilla base es la misma de la Tarea 2, 552003. En la Parte 0 cada escenario usa un múltiplo distinto, para que ningún escenario comparta números aleatorios con otro, y las diez repeticiones de la validación cruzada de 5.2 usan los diez primeros múltiplos. La única semilla que no sale de 552003 es la del desempate de 6.2, que el enunciado fija en 2026.

Tabla 1: Semillas de cada experimento.

Experimento	Semilla usada
AR(1) con $\phi = 0,\ 0.5,\ 0.9,\ 1$ (0.2)	$552003 \cdot 1$, $\cdot 2$, $\cdot 3$, $\cdot 4$
Tendencia lineal (0.4 a)	$552003 \cdot 5$
Patrón semanal (0.4 b)	$552003 \cdot 6$
Validación cruzada aleatoria (5.2 a)	$552003 \cdot k$, $k = 1, \ldots, 10$
Desempate de los puntajes RFM (6.2)	2026 (fijada por el enunciado)

Parte 0: procesos simulados

Inciso 0.1: momentos del AR(1) y de la caminata aleatoria

Sea $Y_t = c + \phi Y_{t-1} + \varepsilon_t$ con $\varepsilon_t \overset{iid}{\sim} N(0, \sigma^2)$, $|\phi| < 1$ y el proceso estacionario, de modo que $E[Y_t] = E[Y_{t-1}] = \mu$ y $\mathrm{Var}(Y_t) = \mathrm{Var}(Y_{t-1}) = \gamma_0$.

Media. Tomando esperanza en los dos lados y usando $E[\varepsilon_t] = 0$,

$$\mu = c + \phi\mu \quad \Longrightarrow \quad \mu(1-\phi) = c \quad \Longrightarrow \quad E[Y_t] = \frac{c}{1-\phi}.$$

La división es válida porque $\phi \neq 1$.

Varianza. La constante no aporta varianza. Y_{t-1} depende solo de $\varepsilon_{t-1}, \varepsilon_{t-2}, \ldots$, así que es independiente de ε_t y la covarianza cruzada es cero:

$$\gamma_0 = \mathrm{Var}(\phi Y_{t-1} + \varepsilon_t) = \phi^2\gamma_0 + \sigma^2 \quad \Longrightarrow \quad \mathrm{Var}(Y_t) = \frac{\sigma^2}{1-\phi^2},$$

que es positiva porque $\phi^2 < 1$.

Autocorrelación. Para $k \geq 1$, ε_t también es independiente de Y_{t-k}, así que

$$\gamma_k = \mathrm{Cov}(c + \phi Y_{t-1} + \varepsilon_t,\ Y_{t-k}) = \phi\,\mathrm{Cov}(Y_{t-1}, Y_{t-k}) = \phi\,\gamma_{k-1}.$$

Aplicando la recursión k veces, $\gamma_k = \phi^k\gamma_0$, y dividiendo entre γ_0, $\rho_k = \phi^k$.

Caminata aleatoria. Con $\phi = 1$, $c = 0$ y $Y_0 = 0$, desenrollando la recursión, $Y_t = \varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t$. Como los ε_i son independientes, las varianzas se suman:

$$\mathrm{Var}(Y_t) = \sum_{i=1}^{t} \mathrm{Var}(\varepsilon_i) = t\sigma^2.$$

La varianza crece con t, y la estacionariedad débil exige que no dependa del momento en que se observa. También la covarianza depende de t, porque $\mathrm{Cov}(Y_t, Y_{t-k}) = (t-k)\sigma^2$. La fórmula de la varianza estacionaria lo anticipa, ya que con $\phi = 1$ queda $\sigma^2/0$ y no hay ninguna varianza fija a la que el proceso pueda llegar.

Inciso 0.2: simulación

La función `simular_ar1` arranca en $Y_0 = 0$, avanza 500 pasos y conserva los últimos 300, con $c = 0$ y $\sigma = 1$. Para $\phi < 1$ el calentamiento sirve porque el efecto del valor inicial se apaga como ϕ^{200}, que con $\phi = 0.9$ ya vale 7×10^{-10}. Con $\phi = 1$ no se apaga nunca, pero tampoco importa para r_k. Lo que se conserva es $Y_{200} + (\varepsilon_{201} + \cdots + \varepsilon_t)$, es decir, una caminata que arranca en el valor Y_{200} en vez de en cero. Sumarle una constante a toda la serie también se la suma a $\bar{y}$, y r_k solo usa las desviaciones $y_t - \bar{y}$, que no cambian. Por eso r_k es el mismo arranque donde arranque.

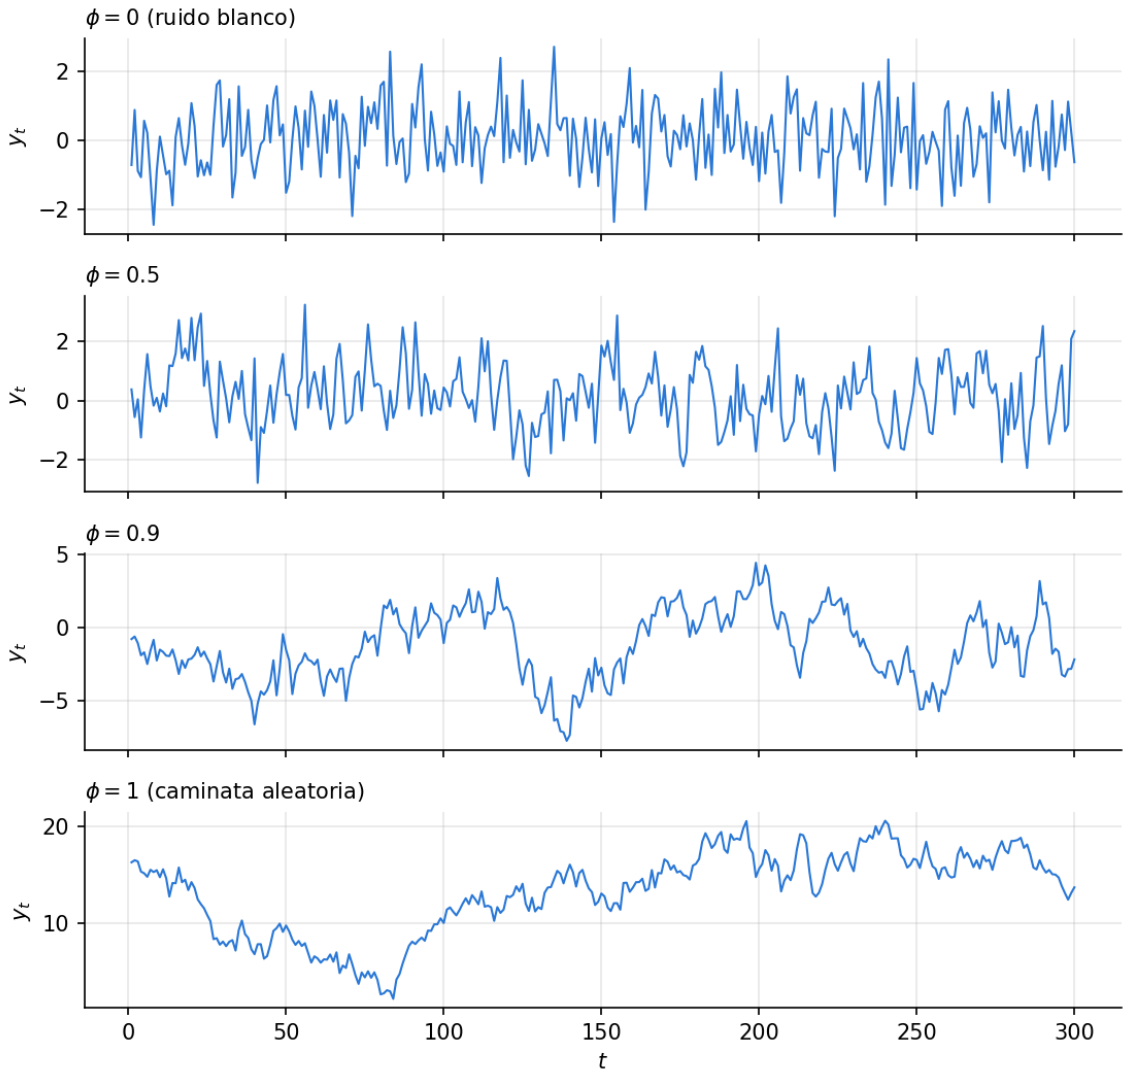


Figura 1: Una realización de cada AR(1). Con $\phi = 0$ la serie no tiene ninguna inercia. Con $\phi = 0.5$ se ven rachas cortas, con $\phi = 0.9$ rachas largas que siempre vuelven a cero, y la caminata aleatoria se aleja sin volver a ninguna media.

La tabla 2 resume las 5 000 réplicas de cada escenario. Entre paréntesis va el error estándar del promedio, $s/\sqrt{5000}$, y para la tasa de rechazo $\sqrt{\hat{p}(1-\hat{p})/5000}$, porque una tasa es el promedio de una indicadora.

Tabla 2: Resultados de 5 000 réplicas de $n = 300$ por escenario. Entre paréntesis, el error estándar de cada promedio.

ϕ	$\bar{r}_1$	$\bar{r}_5$	ϕ^5	Tasa de rechazo con r_1	$\hat{\phi}_{\text{OLS}}$
0	-0.0015 (0.0008)	-0.0038 (0.0008)	0.0000	0.0522 (0.0031)	-0.0015 (0.0008)
0.5	0.4905 (0.0007)	0.0211 (0.0010)	0.0312	1.0000 (0.0000)	0.4922 (0.0007)
0.9	0.8837 (0.0004)	0.5333 (0.0014)	0.5905	1.0000 (0.0000)	0.8870 (0.0004)
1	0.9752 (0.0002)	0.8810 (0.0009)	1.0000	1.0000 (0.0000)	0.9817 (0.0002)

Inciso 0.3: lo que dice la tabla

Ruido blanco. Con $\phi = 0$ la prueba rechaza en el 5.22 % de las réplicas, a menos de un error estándar del 5 % nominal. Es lo que se esperaba, porque bajo ruido blanco $r_1 \approx N(0, 1/n)$ y la banda $\pm 1.96/\sqrt{n}$ está construida para dejar fuera justo el 5 % de esa normal. Cada rechazo aquí es un error tipo I, como el rechazo de Blum Blum Shub en la Tarea 2. Con $\phi = 0.5$ en adelante la prueba rechaza siempre, porque r_1 queda a más de cuatro bandas de cero.

Caminata aleatoria. La teoría $\rho_5 = \phi^5$ dice 1 y la simulación da 0.881. La fórmula $\rho_k = \phi^k$ se derivó suponiendo estacionariedad, y la caminata no lo es, así que no hay ningún ρ_k que estimar. Lo que mide r_k en una caminata es qué tanto se parece la trayectoria a sí misma corrida k pasos, y como $\bar{y}$ es la media de una sola trayectoria que deambula, r_k sale grande pero lejos de 1 y bajando despacio con k (figura 3). La firma de una serie no estacionaria es justamente esa ACF que no cae.

Sesgo del OLS. El estimado de ϕ queda siempre por debajo del verdadero, y el sesgo crece con ϕ: -0.0015, -0.0078, -0.0130 y -0.0183. Para $\phi = 0.5$ y 0.9 cuadra con la aproximación clásica $-(1+3\phi)/n$, que da -0.0083 y -0.0123. Para la caminata el sesgo es más grande que lo que predice esa fórmula, porque ahí la distribución del estimador deja de ser normal (es la distribución de Dickey–Fuller). El sesgo aparece porque el regresor y_{t-1} no es independiente de los errores pasados y porque se estima la media con la misma muestra. Aun así el estimador es consistente, ya que el sesgo es de orden $1/n$ y desaparece al crecer la muestra. Con 300 datos es pequeño frente al error de una réplica suelta, pero para $\phi \geq 0.5$ está a más de diez errores estándar de cero, así que es un sesgo y no ruido. El promedio de r_1 subestima todavía más que el OLS (0.8837 contra 0.8870 con $\phi = 0.9$).

Inciso 0.4: las dos razones para reprobar

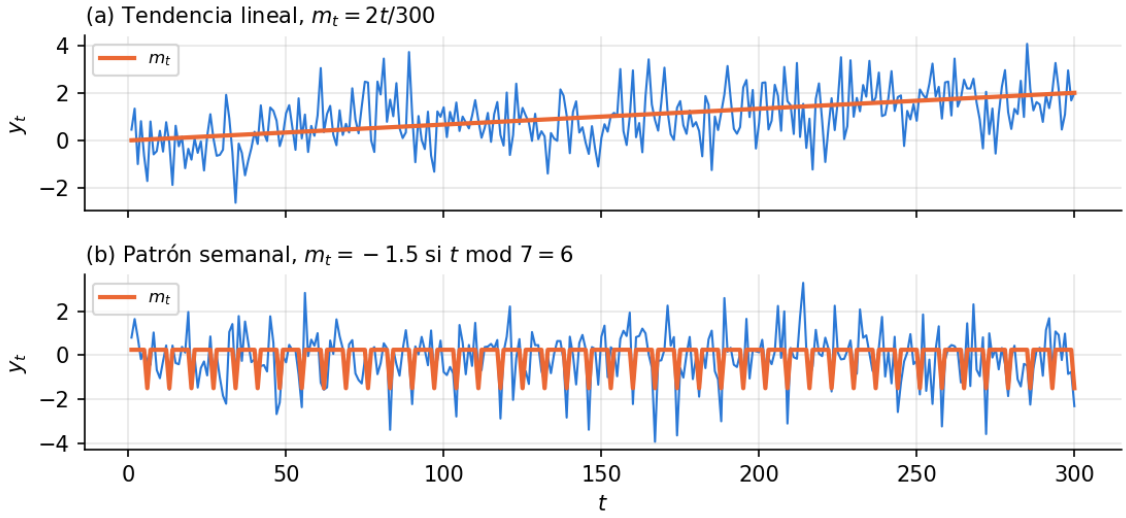


Figura 2: Una realización de cada proceso sin memoria. En naranja la media m_t, que es lo único que cambia con el tiempo. El ruido alrededor de m_t es independiente día a día.

Tabla 3: Procesos sin memoria con media que cambia en el tiempo, 5 000 réplicas cada uno. El ruido blanco se repite como referencia.

Proceso	$\bar{r}_1$	$\bar{r}_5$	$\bar{r}_7$	Tasa de rechazo con r_1	$\hat{\phi}_{\text{OLS}}$
Ruido blanco ($\phi = 0$)	-0.0015 (0.0008)	-0.0038 (0.0008)	-0.0036 (0.0008)	0.0522 (0.0031)	-0.0015 (0.0008)
(a) Tendencia lineal	0.2455 (0.0008)	0.2359 (0.0008)	0.2304 (0.0008)	0.9850 (0.0017)	0.2467 (0.0008)
(b) Patrón semanal	-0.0467 (0.0007)	-0.0481 (0.0007)	0.2640 (0.0008)	0.1054 (0.0043)	-0.0470 (0.0007)

La tendencia lineal reprueba la prueba de retardo 1 en el 98.5 % de las réplicas aunque no tiene memoria. El mecanismo es el de la razón (2) del enunciado: $\bar{y}$ queda a media altura, los días del principio están todos por debajo y los del final todos por encima, y dos días vecinos casi siempre caen del mismo lado. Por eso r_1, r_5 y r_7 salen casi iguales (0.25, 0.24, 0.23). Una memoria verdadera decaería como ϕ^k. Aquí no decae porque no hay memoria, sino un nivel que se mueve. El OLS cae en la misma trampa y reporta un $\hat{\phi} = 0.247$ que no existe.

El patrón semanal hace lo contrario: tiene una estructura muy marcada y pasa la prueba en casi nueve de cada diez réplicas. Su r_1 es -0.047, y se puede calcular a mano. Las desviaciones de m_t respecto a su media (que es cero) son 0.25 seis días y -1.5 uno, así que de los siete productos de vecinos de cada semana cinco valen 0.0625 y dos valen -0.375, en total -0.4375 por semana. Dividido entre la varianza total por día, $0.375+1$, da $-0.4375/(7 \cdot 1.375) = -0.045$. Es un número tan pequeño que queda dentro de la banda. Toda la estructura está en el rezago 7, donde $r_7 = 0.264$ (a mano, $0.375/1.375 = 0.273$). El rechazo sube de 5 % a 10.5 % solo porque r_1 está corrido un poco hacia abajo.

Ese segundo caso es RANDU en la Tarea 2. RANDU pasó la prueba de autocorrelación de retardo 1 con un p-valor cómodo y, sin embargo, cada número está determinado por los dos anteriores ($x_{k+2} = 6x_{k+1} - 9x_k$), y por eso todas las ternas caen en 15 planos. En los dos casos la estructura vive en un lugar que la prueba no mira (el rezago 7 aquí, las ternas allá). Una prueba solo ve dependencia en los rezagos que examina.

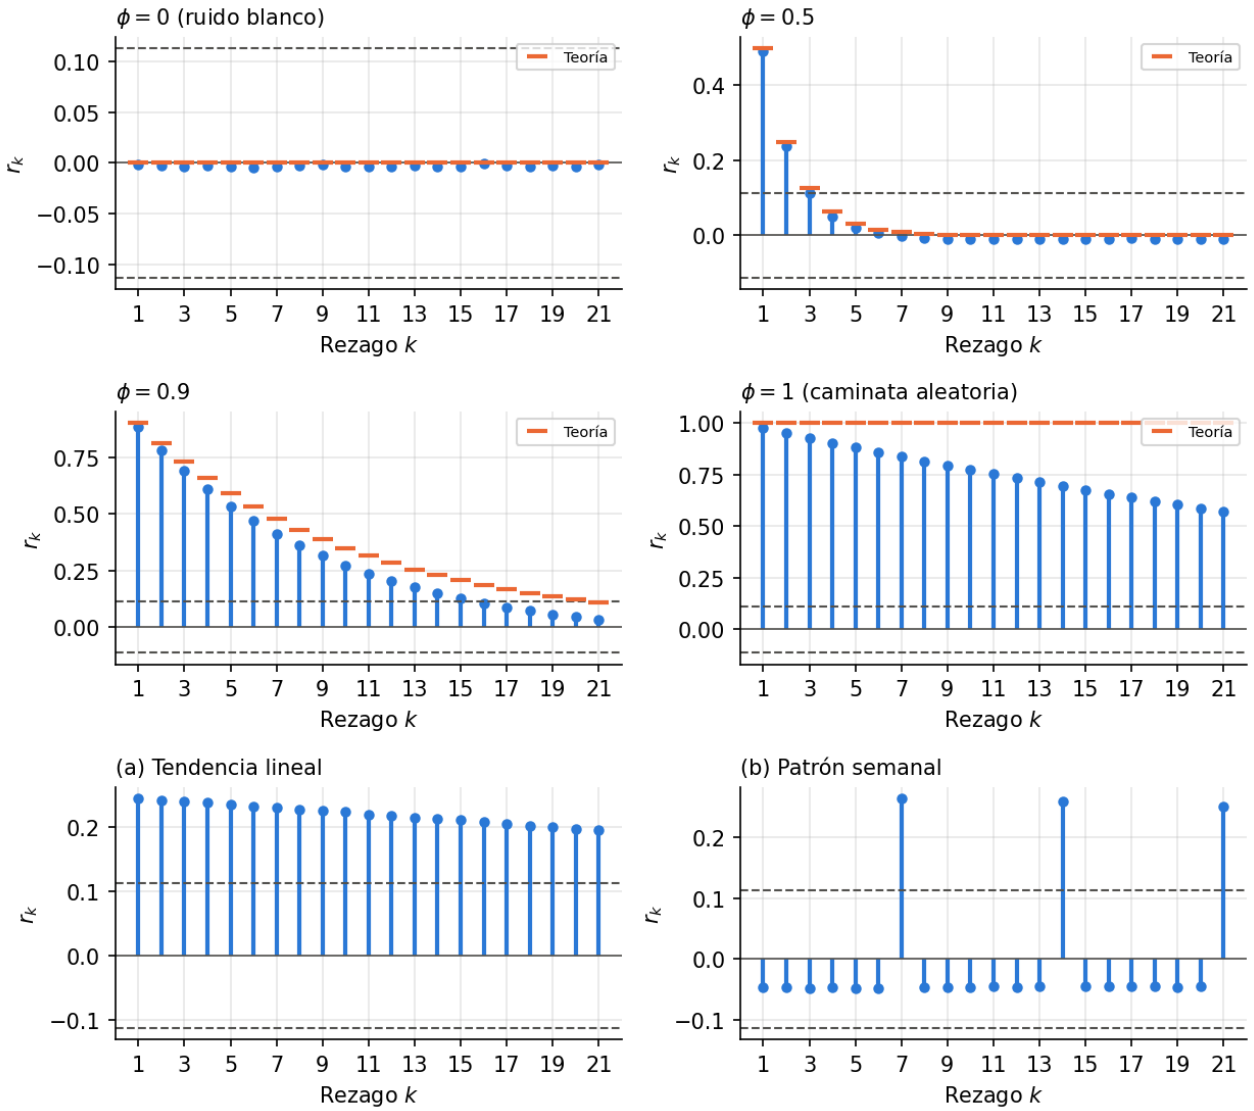


Figura 3: ACF promedio de las 5 000 réplicas de cada proceso, con las bandas $\pm 1.96/\sqrt{300}$. En naranja, la teoría ϕ^k para los AR(1). La tendencia produce una ACF alta y casi plana sin tener memoria, y el patrón semanal produce picos en 7, 14 y 21 con r_1 casi nulo.

Inciso 0.5: la prueba que sí ve

La Ljung–Box propia (`autocorrelacion.ljung_box`) se comparó contra `acorr_ljungbox` de statsmodels en las 15 000 series de la tabla 4. La diferencia máxima en $Q(10)$ fue de 4×10^{-13}, que es redondeo de punto flotante. Se reportan los dos valores de m que discute el enunciado: $m = 10$ de FPP2 y $m \approx \log 300 = 5.7$, que se redondea a 6, de Tsay.

Tabla 4: Tasa de rechazo al 5 % de cada prueba, 5 000 réplicas por proceso.

Proceso	Prueba con r_1	Ljung–Box ($m = 6$)	Ljung–Box ($m = 10$)
Ruido blanco ($\phi = 0$)	0.0522 (0.0031)	0.0508 (0.0031)	0.0508 (0.0031)
(a) Tendencia lineal	0.9850 (0.0017)	1.0000 (0.0000)	1.0000 (0.0000)
(b) Patrón semanal	0.1054 (0.0043)	0.2004 (0.0057)	0.9546 (0.0029)

Con ruido blanco la Ljung–Box rechaza el 5.08 %, igual que el nivel nominal, así que juntar rezagos no infla el error tipo I. La tendencia la reprueban todas. El cambio está en el patrón semanal: con $m = 10$ el rechazo pasa del 10.5 % de la prueba de retardo 1 al 95.5 %, porque $Q(10)$ suma r_7^2 y r_7 es grande. Con $m = 6$ se queda en 20 %, porque el rezago 7 queda fuera de la suma, y lo poco que sube viene de que los $r_1, \ldots, r_6$ están todos corridos a -0.047. La comparación entre los dos libros se decide sola en este caso. La regla de FPP2 ($m = 10$ sin estacionalidad, $m = 2s$ con ella) cubre el periodo, y $\log n$ no. Una portmanteau solo ve la estacionalidad si m llega hasta el periodo.

Parte 1: limpieza

Inciso 1.1: los datos crudos

El archivo tiene 541 909 filas, 25 900 facturas, 4 070 productos y 4 372 clientes. El 24.93 % de las filas (135 080) no tiene `CustomerID`.

Las tres columnas se leen como texto porque son etiquetas y no cantidades. Si se deja que pandas adivine el tipo, `InvoiceNo` queda como una columna mezclada de 532 618 enteros y 9 291 cadenas. Con eso `.str.startswith("C")` devuelve faltantes en todas las facturas normales y la regla de cancelaciones se rompe. `StockCode` queda con 487 036 enteros y 54 873 cadenas, de modo que `85123` y `85123A` quedan de distinto tipo y no se pueden comparar con una sola expresión regular. `CustomerID` queda como `float64`, porque los faltantes obligan a pandas a usar flotantes, y el cliente 17850 aparece como `17850.0`. Ninguna operación aritmética sobre estas columnas tiene sentido.

Inciso 1.2: qué es una venta

El criterio que se adoptó es que cuenta como venta todo lo que es mercancía y todo lo que ajusta el precio de mercancía vendida. Lo que es un cobro distinto (envío, comisiones) o un movimiento de inventario se va.

(a) Duplicados exactos: se van. Hay 5 268 filas idénticas a otra en las ocho columnas, incluida la hora al minuto. Una misma factura no repite el mismo producto en dos líneas idénticas (lo normal es sumar la cantidad), así que se tratan como registros dobles del sistema. Representan £21 741 netas.

(b) Facturas que no empiezan con dígito. Hay dos prefijos. Las 9 288 filas con C (3 836 facturas) son cancelaciones y se quedan: todas traen ya la cantidad negativa, así que no hace falta transformarlas, y al sumar restan el día en que ocurren, como pide el enunciado. Las 3 filas con A (`A563185` a `A563187`) son asientos contables "Adjust bad debt" por £11 062.06, sin cliente ni producto. Se van, porque una deuda incobrable no es una venta.

(c) Códigos que no son productos. La tabla 5 lista los códigos que no empiezan con cinco dígitos. No todos son iguales. `DCGS*`, los vales de regalo `gift_0001_*` y `PADS` son productos con código especial y se quedan. Los envíos (`POST`, `DOT`, `C2`) son un cobro aparte de la mercancía (casi todo `DOT` va sin cliente), y las comisiones de Amazon, del banco y de CRUK son costos de la tienda, no ventas, así que todos se van. Las muestras `S` y la deuda `B` también se van. `M` (ajuste manual) y `D` (descuento) se quedan porque corrigen el precio de ventas que sí ocurrieron. El caso que lo decide está en el

inciso 1.4: sin `M` quedaría contada una venta de £38 970 que la tienda anuló con un ajuste manual tres minutos después.

Tabla 5: Códigos de `StockCode` que no empiezan con cinco dígitos, en los datos crudos.

Código	Descripción	Filas	Monto (£)	Decisión
`POST`	POSTAGE	1 256	66 230.64	Se va
`DOT`	DOTCOM POSTAGE	710	206 245.48	Se va
`M`	Manual	571	-68 674.19	Se queda
`C2`	CARRIAGE	144	6 986.00	Se va
`D`	Discount	77	-5 696.22	Se queda
`S`	SAMPLES	63	-3 049.39	Se va
`BANK CHARGES`	Bank Charges	37	-7 175.64	Se va
`AMAZONFEE`	AMAZON FEE	34	-221 520.50	Se va
`CRUK`	CRUK Commission	16	-7 933.43	Se va
`B`	Adjust bad debt	3	-11 062.06	Se va
`m`	Manual	1	2.55	Se queda
`DCGS*`	productos con código especial	45	398.45	Se queda
`gift_0001_*`	productos con código especial	34	685.81	Se queda
`PADS`	productos con código especial	4	0.00	Se queda

(d) Precio cero o negativo: se van. Hay 2 515 filas con precio cero y 2 con precio negativo. Las dos negativas son asientos A del inciso (b). Las de precio cero son en un 98 % filas sin cliente (casi todas los ajustes de inventario del inciso e), y las que tienen cliente son regalos o muestras sin cobro. No mueven dinero, así que quitarlas no cambia la venta diaria, pero dejarlas inflaría el conteo de facturas, y con él la frecuencia de la Parte 6.

(e) Cantidad negativa sin ser cancelación: se van. Son 1 336 filas, todas con precio cero y sin cliente. Su descripción es una nota de bodega: vacía en 862, y en el resto “check”, “damages”, “damaged”, “?”, “thrown away”, “sold as set on dotcom”. Son ajustes de inventario (mercancía dañada, perdida o recontada) y no una venta devuelta, así que se van. Tampoco mueven dinero.

(f) Filas sin `CustomerID`: se quedan en la serie. En los datos limpios son 131 687 filas (24.8 %) y £1 496 241. Son ventas que ocurrieron aunque no se sepa a quién, así que la venta diaria las necesita. En la Parte 6 la pregunta es quién compró, y ahí no sirven, así que se quitan solo en esa parte.

Inciso 1.3: bitácora de limpieza

Tabla 6: Bitácora de limpieza. Las reglas se aplican en el orden de la primera columna y cada una cuenta solo las filas que siguen vivas. El monto absoluto suma |Quantity × UnitPrice| y muestra cuánto dinero movían esas filas aunque se compensen entre sí.

Orden	Regla	Filas eliminadas	Neto (£)	Absoluto (£)
1	Duplicados exactos	5 268	21 740.98	27 406.50
2	Facturas con prefijo A (ajuste de deuda)	3	-11 062.06	33 186.18
3	Cantidad negativa sin ser cancelación	1 336	0.00	0.00
4	Códigos que no son mercancía	2 259	39 792.90	570 988.68
5	Precio igual a cero o negativo	1 166	0.00	0.00
–	Sin `CustomerID` (se quedan en la serie)	131 687	1 496 240.86	1 573 779.90
	Datos crudos	541 909	9 747 747.93	
	Datos limpios	531 877	9 697 276.11	

El orden cambia los conteos. La regla 5 solo quita 1 166 filas porque 1 351 de las que cumplen esa condición ya se habían ido: las 1 336 de cantidad negativa (todas con precio cero), las dos de

precio negativo y 13 que ya habían caído como duplicados o códigos que no son mercancía. Si fuera primera, quitaría 2 517. El monto neto de la regla 4 es pequeño (£39 793) pero su monto absoluto es de £571 000, porque mezcla £279 000 de envíos con £221 000 de comisiones de Amazon que se compensan. Esas líneas mueven mucho dinero aunque su suma neta sea pequeña. La limpieza completa quita 10 032 filas y cambia la venta total en solo 0.5 %, pero lo que quita está concentrado en días puntuales (la mitad de las comisiones de Amazon pasan de £5 900 y la más grande es de £17 836) y movería esos días bastante.

Inciso 1.4: las seis líneas más grandes

Tabla 7: Las seis líneas con mayor |Quantity × UnitPrice| en los datos crudos.

Factura	Código	Descripción	Cantidad	Precio	Fecha	Cliente	Monto (£)
581483	23843	PAPER CRAFT , LITTLE BIRDIE	80 995	2.08	09/12/2011 09:15	16446	168 469.60
C581484	23843	PAPER CRAFT , LITTLE BIRDIE	-80 995	2.08	09/12/2011 09:27	16446	-168 469.60
541431	23166	MEDIUM CERAMIC TOP STORAGE JAR	74 215	1.04	18/01/2011 10:01	12346	77 183.60
C541433	23166	MEDIUM CERAMIC TOP STORAGE JAR	-74 215	1.04	18/01/2011 10:17	12346	-77 183.60
556444	22502	PICNIC BASKET WICKER 60 PIECES	60	649.50	10/06/2011 15:28	15098	38 970.00
C556445	M	Manual	-1	38970.00	10/06/2011 15:31	15098	-38 970.00

Las seis líneas son tres pedidos y sus tres anulaciones, y en los tres casos la anulación llegó el mismo día y en minutos.

- 80 995 PAPER CRAFT, LITTLE BIRDIE (£168 470). El cliente 16446 solo había hecho una compra de £2.90 en mayo. A las 9:15 del 9 de diciembre aparece un pedido de casi 81 000 unidades, y doce minutos después la cancelación exacta. Es un error de captura de la cantidad.
- 74 215 MEDIUM CERAMIC TOP STORAGE JAR (£77 184). El cliente 12346 tiene en todo el año esas dos líneas y nada más: el pedido y su cancelación dieciséis minutos después. Es el mismo tipo de error.
- 60 PICNIC BASKET WICKER 60 PIECES (£38 970). El cliente 15098 compró a las 15:22 sesenta canastas pequeñas a £4.95. A las 15:28 se registró el paquete de 60 piezas con cantidad 60 y precio £649.50, que es el precio del paquete completo, así que se cobraron 60 paquetes. A las 15:31 un ajuste manual `M` devolvió exactamente £38 970. A las 15:33 se volvió a registrar el paquete con cantidad 1, y a las 15:39 se cancelaron las sesenta canastas sueltas. El neto del cliente ese día es £649.50, que es lo que de verdad compró.

La limpieza no las resuelve, y no debería. Las seis sobreviven, porque son productos o ajustes `M` y las cancelaciones se quedan a propósito. Una regla que borrara cantidades "demasiado grandes" quitaría el pedido y dejaría su cancelación, y eso inventaría un día con £168 000 negativos. Lo que sí las resuelve es netear por día: cada par cae el mismo día y suma cero, y en el caso del picnic el día queda con los £649.50 correctos. La primera además cae en el 9 de diciembre, que se descarta en el inciso 2.4. Por cliente el neteo resuelve el monto pero no la frecuencia. El cliente 12346 llega a la Parte 6 con $F = 1$ y $M = 0$.

Inciso 1.5: la función `limpiar`

Toda la limpieza está en `codigo/limpieza_datos.py`. Las cinco reglas están escritas una sola vez, como una lista de pares (nombre, máscara), y la recorren las dos funciones del módulo: `limpiar(df)` devuelve el `DataFrame` limpio, con el índice original para poder rastrear cada fila, y `bitacora(df)`

devuelve la tabla 6. Así la bitácora no puede contradecir lo que hace la limpieza. `cargar_datos` lee el `.xlsx` con las tres columnas como texto y agrega la columna `Monto`.

Parte 2: el calendario

Incisos 2.1 y 2.2: días con y sin transacciones

Del 1 de diciembre de 2010 al 9 de diciembre de 2011, incluyendo los dos, hay 374 días calendario, y en 305 hubo al menos una transacción. Los 69 restantes están en la tabla 8, salvo los sábados. La tienda no abre los sábados: faltan los 53 sábados del periodo y no hay ni una transacción en sábado en todo el archivo.

Tabla 8: Días sin transacciones que no son sábado. Los bank holidays son los de Inglaterra y Gales publicados en gov.uk.

Fecha	Día	Razón del cierre	£Es móvil?
24/12/2010	Viernes	Cierre de Navidad y Año Nuevo	No
26/12/2010	Domingo	Cierre de Navidad y Año Nuevo	No
27/12/2010	Lunes	Bank holiday: Christmas Day (sustituto)	No
28/12/2010	Martes	Bank holiday: Boxing Day (sustituto)	No
29/12/2010	Miércoles	Cierre de Navidad y Año Nuevo	No
30/12/2010	Jueves	Cierre de Navidad y Año Nuevo	No
31/12/2010	Viernes	Cierre de Navidad y Año Nuevo	No
02/01/2011	Domingo	Cierre de Navidad y Año Nuevo	No
03/01/2011	Lunes	Bank holiday: New Year's Day (sustituto)	No
22/04/2011	Viernes	Bank holiday: Good Friday	Sí
24/04/2011	Domingo	Domingo de Pascua	Sí
25/04/2011	Lunes	Bank holiday: Easter Monday	Sí
29/04/2011	Viernes	Bank holiday: Boda real (Guillermo y Catalina)	No
02/05/2011	Lunes	Bank holiday: Early May bank holiday	No
30/05/2011	Lunes	Bank holiday: Spring bank holiday	No
29/08/2011	Lunes	Bank holiday: Summer bank holiday	No

Los 16 días que no son sábado son de dos tipos. El primero es el cierre de fin de año, del viernes 24 de diciembre al lunes 3 de enero. Como Navidad, Boxing Day y Año Nuevo de 2010–2011 cayeron en sábado o domingo, sus feriados se pasaron a los lunes y martes siguientes (27 y 28 de diciembre, 3 de enero), y la tienda cerró además los días intermedios. El segundo tipo son los bank holidays de 2011: Viernes Santo, Lunes de Pascua (más el Domingo de Pascua), los dos de mayo y el de agosto, y el que no se repite: el 29 de abril de 2011, la boda del príncipe Guillermo y Catalina Middleton, que se declaró feriado solo ese año.

Móviles, en el sentido de FPP2, son los tres de Pascua. Viernes Santo y Lunes de Pascua dependen de la fecha de Pascua, que cambia según el calendario lunar y puede caer en marzo o en abril. Eso los hace difíciles de modelar con datos diarios, porque de un año a otro caen en una semana distinta. Los bank holidays de mayo y agosto cambian de fecha, pero siempre son el primer o el último lunes del mes, así que una variable de calendario los anticipa sin problema.

Inciso 2.3: ¿cero o faltante?

Depende de para qué se use la serie. Un día cerrado es un cero cuando lo que se mide es dinero acumulado: la venta del mes, el flujo de caja de la semana o la media móvil de la Parte 3, que debe repartir la venta de una semana entre sus siete días. El 25 de diciembre la tienda vendió exactamente

cero libras, y al sumar el mes ese cero es correcto. Un día cerrado es un faltante cuando lo que se modela es la demanda de un día en que la tienda abre: la media de los lunes, la ACF o el pronóstico de cualquier modelo de las Partes 4 y 5. Un lunes feriado no es un lunes en que nadie quiso comprar. Si se mete como cero, baja la media de los lunes, crea picos falsos en la ACF y le enseña al modelo que de vez en cuando un lunes vende cero, cosa que nunca pasa con la tienda abierta.

Inciso 2.4: el último día

El 9 de diciembre no está completo. La primera factura es de las 8:39 y la última de las 12:50, cuando la mediana de la última factura de cada día es a las 17:26. Tiene 49 facturas y, ya limpio, £29 306 de venta neta, cuando los cuatro viernes anteriores vendieron entre £46 600 y £55 400. Los datos se cortaron a media jornada, y si el día se queda se lee como una caída de ventas que no ocurrió. Además es el día del pedido de 80 995 unidades. Se descarta, y la serie de trabajo va del 1 de diciembre de 2010 al 8 de diciembre de 2011. El entrenamiento son los 245 días abiertos hasta el 30 de septiembre, y la prueba los 58 días abiertos del 3 de octubre al 8 de diciembre.

Parte 3: tendencia, estacionalidad y autocorrelación

Inciso 3.1: tendencia

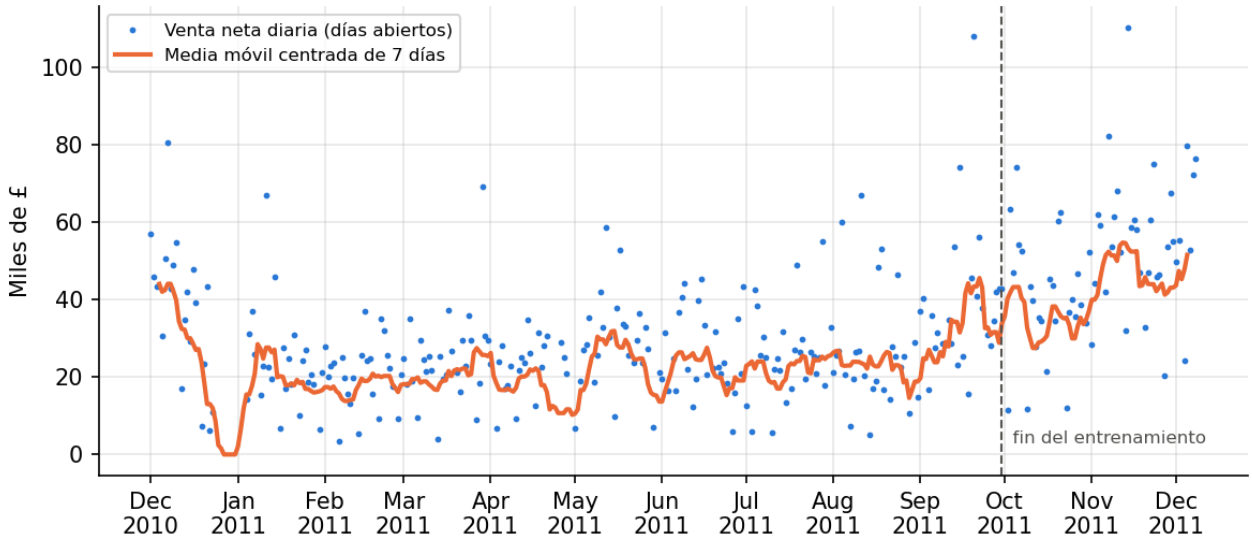


Figura 4: Venta neta diaria de los días abiertos (puntos) y media móvil centrada de 7 días calculada sobre el calendario completo con los días cerrados en cero (línea).

7 y no 5 ni 30 porque el ciclo de la serie es semanal: una ventana de siete días calendario contiene exactamente un día de cada tipo (cinco días de semana, un sábado cerrado y un domingo flojo), así que el patrón semanal se cancela y queda solo el nivel. Una ventana de 5 contiene a veces el sábado y el domingo y a veces ninguno, y la media oscila con el ciclo semanal. Una de 30 no es múltiplo de 7, así que según dónde caiga cuenta cuatro o cinco domingos, y además aplana cambios reales como el cierre de Navidad o la subida de septiembre. Centrada para que MA_t hable del día t. Una media de los siete días anteriores describe el nivel de hace tres días y llega tarde a cualquier cambio de tendencia. La media centrada no tiene ese retraso.

La serie empieza alta en diciembre de 2010 (unas £40 000 diarias), cae a cero con el cierre de fin de año y pasa enero a agosto casi plana, mayormente entre £15 000 y £30 000 de media móvil, con caídas puntuales en las semanas de feriados (Semana Santa, la boda real y los feriados de mayo) y una subida leve desde mayo. En septiembre arranca una subida fuerte que lleva el nivel a unas £47 000 en noviembre y diciembre, el doble que en verano. Es la temporada navideña de una tienda que vende regalos a mayoristas, y diciembre de 2010 sugiere que el mismo pico ocurrió el año anterior.

Inciso 3.2: estacionalidad

Tabla 9: Índice estacional de cada día abierto: promedio de y_t/MA_t sobre los días abiertos del entrenamiento.

Lunes	Martes	Miércoles	Jueves	Viernes	Domingo	Promedio
1.164	1.545	1.232	1.563	1.118	0.580	1.200

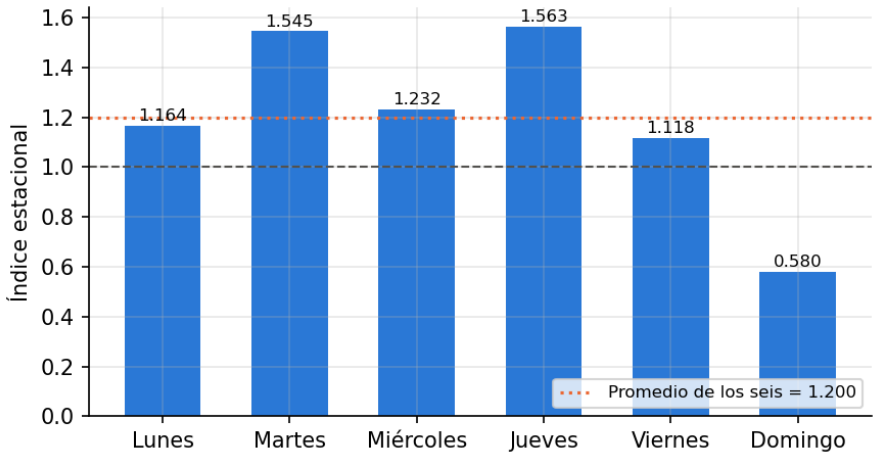


Figura 5: Índice estacional por día de la semana. La línea gris marca 1 y la punteada el promedio de los seis índices.

Martes y jueves son los días fuertes, con un 55 % más que la media móvil. Lunes, miércoles y viernes quedan en torno a 1.2, y el domingo vende poco más de la mitad. El promedio de los seis índices es 1.200 y no 1 porque la media móvil reparte la venta de la semana entre siete días, sábado incluido, y el sábado siempre vale cero. Toda la venta de la semana la hacen los seis días abiertos, así que en promedio cada uno queda $7/6 \approx 1.167$ veces arriba de la media móvil. El 1.200 pasa de 1.167 por dos razones. Las semanas con feriado tienen solo cinco días abiertos y su cociente se acerca a $7/5$, y el promedio de cocientes no es el cociente de los promedios.

Inciso 3.3: autocorrelación

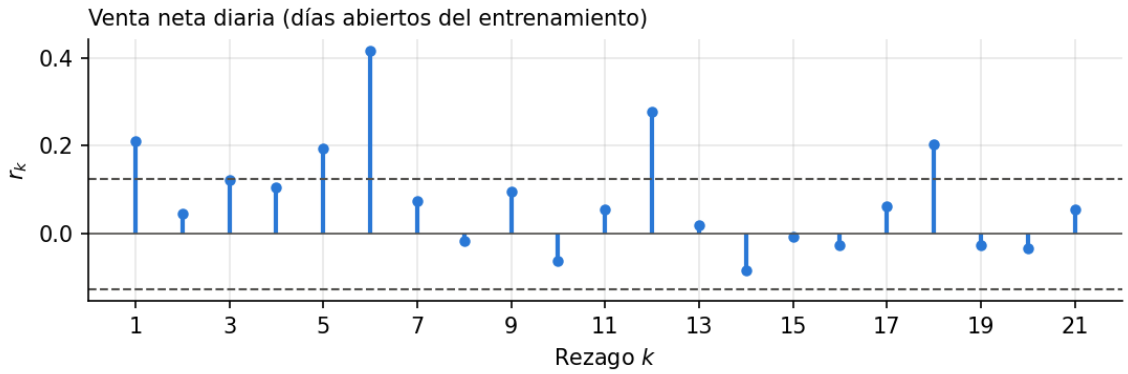


Figura 6: ACF de la venta neta diaria sobre los 245 días abiertos del entrenamiento, una fila por día, con las bandas $\pm 1.96/\sqrt{245} = \pm 0.125$.

(a) De los 21 rezagos se salen 5: el 1, 5, 6, 12 y 18. Con $r_1 = 0.210$ la serie reprueba la prueba de retardo 1 de la Tarea 2, que rechaza con $|r_1| > 0.125$. El pico está en el rezago 6 ($r_6 = 0.416$), y como no hay sábados, seis filas atrás es el mismo día de la semana anterior, es decir, siete días calendario. Los rezagos 12 y 18 son las semanas 2 y 3. En las semanas con feriado hay solo cinco días abiertos, y ahí el mismo día de la semana anterior queda cinco filas atrás; eso ayuda a explicar que el rezago 5 también se salga. La Ljung–Box no deja duda: $Q(6) = 71.4$ con $p = 2 \times 10^{-13}$ y $Q(12) = 96.9$ con $p = 2 \times 10^{-15}$. Los dos valores de m corresponden a los dos libros: $\log 245 = 5.5 \approx 6$ es el de Tsay y $2s = 12$ con $s = 6$ es el de FPP2, y aquí los dos cubren el periodo de 6 filas.

(b) Con lo de la Parte 0 se pueden separar dos cosas. Los picos en 6, 12 y 18 son el patrón semanal, la misma huella que el proceso (b) de 0.4, y son media no constante, no memoria. Lo que queda por debajo, una autocorrelación positiva en casi todos los rezagos cortos que baja despacio, se parece a la tendencia del proceso (a), que es el nivel que sube en septiembre y el salto de diciembre. Puede haber algo de memoria verdadera mezclada, pero con esta gráfica no se puede separar. La Parte 4 quita primero lo que es media y después mira qué queda.

Parte 4: del AR(1) al SARIMA

Incisos 4.1 y 4.2: quitar el día de la semana y probar un AR(1)

La regresión contra las seis indicadoras, sin intercepto, estima la media de cada día: lunes £26 920, martes £34 990, miércoles £27 697, jueves £35 270, viernes £26 211 y domingo £13 706. Sus residuos e_t son la venta menos la media de su día.

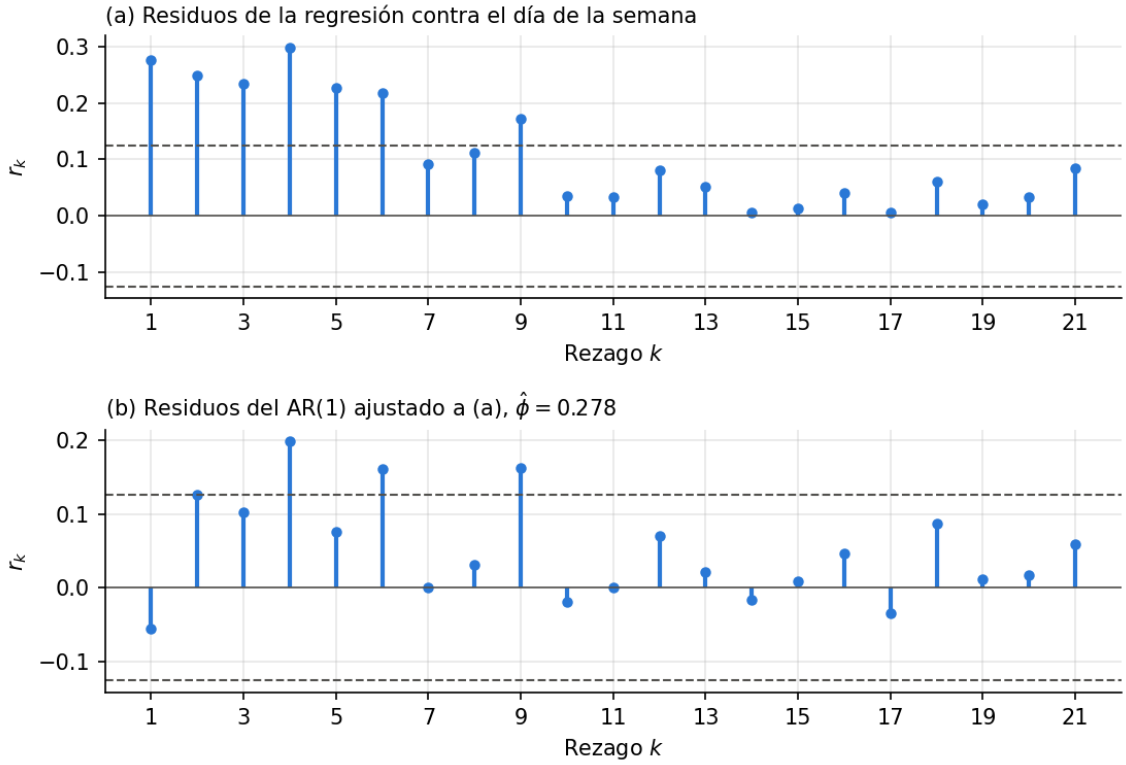


Figura 7: (a) ACF de los residuos de la regresión contra el día de la semana. (b) ACF de los residuos u_t del AR(1) ajustado a esos residuos. Bandas $\pm 1.96/\sqrt{n}$.

4.1. Los picos de 6, 12 y 18 desaparecieron, así que el patrón semanal sí era media no constante y las indicadoras lo absorben. Pero ahora se salen los rezagos 1 a 6 y el 9, todos entre 0.17 y 0.30, y la Ljung–Box empeora ($Q(6) = 95.2$, $Q(12) = 110.3$, $p < 10^{-17}$). La forma no es la de un AR(1). Con $r_1 = 0.28$ un AR(1) daría $r_2 = 0.08$ y $r_4 = 0.006$, y aquí r_4 vale 0.30. Se parece a la ACF de la tendencia de la figura 3: valores parecidos en muchos rezagos seguidos que bajan muy despacio. Al modelo le falta el nivel. Las indicadoras suponen que un martes de febrero y uno de noviembre esperan lo mismo, y la figura 4 muestra que no, así que los días de diciembre de 2010 y de septiembre quedan con residuo positivo y los de enero a agosto con residuo negativo.

4.2. El AR(1) por OLS sobre e_t da $\hat{\phi} = 0.278$ (y $\hat{c} = -101.75$, prácticamente cero, como debe ser con residuos de media cero). Sus residuos u_t ya no tienen autocorrelación en el rezago 1 ($r_1 = -0.056$), pero siguen fuera de las bandas los rezagos 2, 4, 6 y 9, con $r_4 = 0.198$. La Ljung–Box lo confirma con un grado de libertad menos: $Q(6) = 25.1$ con 5 grados y $p = 1.4 \times 10^{-4}$, y $Q(12) = 33.4$ con 11 grados y $p = 4.5 \times 10^{-4}$. No alcanzó. Un AR(1) con $\phi = 0.28$ olvida en dos o tres días y no puede reproducir un nivel que cambia a lo largo de meses. Para eso haría falta un ϕ cercano a 1, o directamente diferenciar. El rezago 6 que reaparece indica además que el efecto del día de la semana no es aditivo. Un martes de septiembre vende más por encima de su media que un martes de febrero, porque la estacionalidad crece con el nivel (es multiplicativa, como la descomposición de la Parte 3).

Inciso 4.3: SARIMA

Se usa $s = 6$ y no 7 porque el modelo trabaja con una fila por día abierto, y una semana tiene seis días abiertos, así que el mismo día de la semana anterior está seis filas atrás. Un $s = 7$ compararía el lunes con el domingo de la semana anterior. La suposición se rompe cada vez que entre dos filas hay

un día de semana cerrado: en el cierre de Navidad, en Semana Santa, el día de la boda real y en los lunes feriados de mayo y agosto. Entonces seis filas atrás ya no es el mismo día de la semana. En el entrenamiento pasa en 28 de las 239 filas que tienen rezago 6, un 12 %.

Se usa el logaritmo porque la variación crece con el nivel. En noviembre las diferencias entre días son de decenas de miles de libras, y en febrero de unos pocos miles. Es el caso en que FPP2 recomienda transformar. El logaritmo además convierte la estacionalidad multiplicativa en aditiva ($\log(T \cdot S \cdot R) = \log T + \log S + \log R$), y al volver con exp el pronóstico siempre sale positivo. Se puede aplicar porque el día con menos venta tiene £3 440 y ningún día abierto tiene venta neta cero o negativa.

Tabla 10: Ajuste de S1 y S2 sobre el logaritmo de la venta de los 245 días abiertos del entrenamiento, con el límite de iteraciones por defecto (50) y con 500.

Modelo	`maxiter`	Convergió	Iteraciones	Log-verosimilitud	Parámetros
S1	50	No	50	-185.20	`intercept = 0.9016, ar.L1 = 0.1870, ar.S.L6 = 0.8883, sigma2 = 0.2863`
S1	500	Sí	80	-160.70	`intercept = 4.2117, ar.L1 = 0.1319, ar.S.L6 = 0.5207, sigma2 = 0.2157`
S2	50	Sí	14	-156.94	`ma.L1 = -0.9142, ma.S.L6 = -0.6698, sigma2 = 0.2131`
S2	500	Sí	14	-156.94	`ma.L1 = -0.9142, ma.S.L6 = -0.6698, sigma2 = 0.2131`

S1 no converge con el límite por defecto. El optimizador se detiene en 50 iteraciones y los parámetros que devuelve están lejos del óptimo. Con 500 converge en 80 iteraciones, la log-verosimilitud mejora en 24.5 puntos y los parámetros cambian mucho: el AR estacional baja de 0.888 a 0.521 y la varianza del error de 0.286 a 0.216. El modelo sin converger sobreestimaba la persistencia semanal, y si no se revisa `mle_retvals` no hay ningún aviso de que esos números están mal. S2 converge en 14 iteraciones y no cambia al subir el límite. En todo lo que sigue S1 se ajusta con `maxiter=500`. Los parámetros de S2 dicen algo del nivel: $\theta = -0.914$ está cerca de -1, y entonces el factor $(1 + \theta B)$ casi cancela la diferencia $(1 - B)$. Es la forma ARIMA del suavizamiento exponencial, con peso $1+\theta = 0.086$ para cada dato nuevo, así que el nivel que sigue S2 se mueve despacio: casi no reacciona a un día suelto y solo se ajusta cuando el cambio dura varias semanas.

Inciso 4.4: diagnóstico

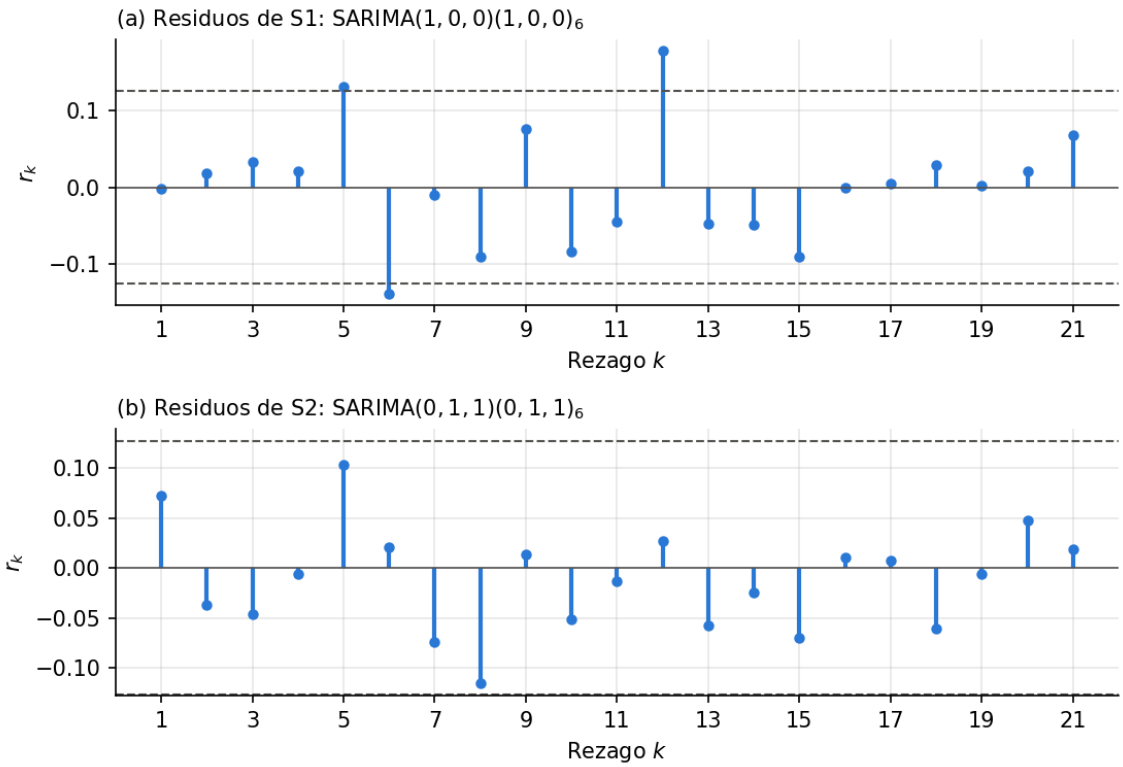


Figura 8: ACF de los residuos de S1 (245 residuos) y de S2 (sin los 7 primeros, 238 residuos), con bandas $\pm 1.96/\sqrt{n}$.

Con $m - 2$ grados de libertad (dos coeficientes ARMA estimados en cada modelo):

Tabla 11: Ljung–Box sobre los residuos de los dos SARIMA.

Modelo	$Q(6)$	p (4 g.l.)	$Q(12)$	p (10 g.l.)
S1	9.57	0.048	23.54	0.009
S2	4.88	0.300	10.49	0.398

S2 deja residuos de ruido blanco. Ninguno de sus 21 rezagos sale de las bandas, y la Ljung–Box no rechaza con ninguno de los dos m. S1 no. Rechaza con $m = 12$ al 1 % y con $m = 6$ apenas al 5 %, y le quedan fuera los rezagos 5, 6 y 12. Es el mismo problema de 4.1 y 4.2: un modelo estacionario supone una media fija, y la media de esta serie se mueve. El AR estacional de S1 copia parte del patrón semanal, pero no puede seguir un nivel que cambia. La doble diferencia de S2 trabaja con cambios y no con niveles, y ahí la media que se mueve deja de ser un problema.

Inciso 4.5: hacia dónde van los pronósticos

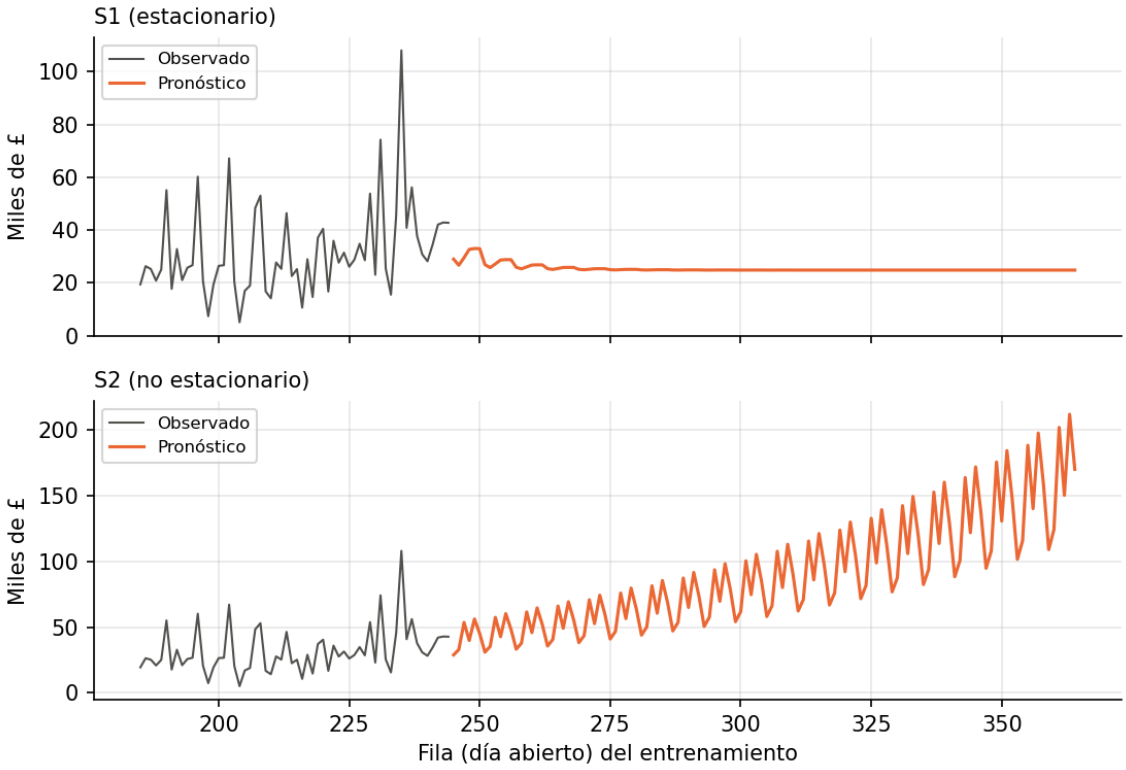


Figura 9: Pronóstico a 120 días abiertos desde el final del entrenamiento, ya en libras, con los últimos 60 días observados en gris.

S1 es estacionario, como el AR(1) con $|\phi| < 1$, así que su pronóstico vuelve a la media. En el AR(1) el pronóstico a h pasos es $\mu + \phi^h(y_n - \mu)$, y $\phi^h \to 0$. Para S1 la media en logaritmo es $c/((1-\phi)(1-\Phi)) = 4.2117/(0.8681 \cdot 0.4793) = 10.12$, que en libras es £24 878, casi la media geométrica del entrenamiento (£24 156). En la figura el pronóstico sale de los últimos valores, conserva unas semanas el patrón semanal (que se apaga como $\Phi^{h/6}$) y a las cinco o seis semanas ya es una línea plana en £24 878, haya pasado lo que haya pasado en septiembre.

S2 no es estacionario, como la caminata aleatoria, así que no vuelve a ninguna media. Su pronóstico arrastra el último nivel y el último patrón semanal, y además una pendiente. $(1-B)(1-B^6) = (1-B)^2(1+B+\cdots+B^5)$ tiene una raíz unitaria doble, y la parte de largo plazo de su pronóstico es un nivel más una recta más un patrón semanal que se repite. La recta sale de la subida de septiembre y, como está en logaritmo, en libras es crecimiento exponencial: a los 120 días abiertos pronostica entre £109 000 y £212 000 diarios. Igual que la varianza de la caminata crece como $t\sigma^2$, la incertidumbre de S2 crece sin límite con el horizonte. A una semana, la cualidad que lo hace absurdo a cuatro meses (seguir el nivel más reciente en lugar de volver al promedio del año) es justo lo que hace falta, como muestra la Parte 5.

Parte 5: pronóstico y fuga

Inciso 5.1: los modelos

Los seis modelos están en `modelos_pronostico.py`. B1 es la media de todos los días abiertos hasta el origen. B2 copia el valor del mismo día de la semana abierto más reciente. M1 es OLS con las seis indicadoras y una tendencia lineal t (días calendario desde el 1 de diciembre de 2010). M2 es OLS con las seis indicadoras, y_{t-7} y y_{t-14}. Si un rezago cae en día cerrado se retrocede de siete en siete hasta un día abierto: para el lunes 9 de mayo los dos rezagos son el 18 de abril, y el script lo verifica. Las filas sin rezago (las dos primeras semanas de diciembre de 2010) no se usan para ajustar. S1 y S2 se reajustan en cada origen con `maxiter=500`. En los 64 ajustes (22 orígenes de (b) y 10 de (c), por dos modelos) `mle_retvals['converged']` fue verdadero.

M2 puede usar y_{t-7} para cualquiera de los siete días siguientes porque el objetivo más lejano es el domingo siguiente, origen +7, y su y_{t-7} es el propio domingo del origen, que ya se observó. Todos los y_{t-7} de la semana caen en la semana que ya pasó. No podría usar y_{t-1}, porque para el martes y_{t-1} es el lunes, que el domingo todavía no ha ocurrido. Funcionaría solo para el primer día de la semana. S1 usa el rezago 1 de todas formas pronosticando de forma recursiva. Para el segundo día usa en lugar de y_{t-1} su propio pronóstico del primero, y así sucesivamente. Es legítimo, porque solo usa información del origen, pero los errores se acumulan con el horizonte.

Inciso 5.2: tres formas de estimar el error

Tabla 12: Error en libras de cada modelo. (a) Validación cruzada aleatoria de 5 folds sobre los 245 días del entrenamiento, media y desviación estándar (entre paréntesis) de 10 repeticiones. (b) Origen móvil semanal con 22 orígenes, del domingo 1 de mayo al 25 de septiembre, 128 días evaluados. (c) Periodo de prueba con origen móvil semanal, 10 orígenes del 2 de octubre al 4 de diciembre, 58 días evaluados.

	(a) CV aleatoria		(b) Origen móvil (entrenamiento)		(c) Prueba	
Modelo	MAE	RMSE	MAE	RMSE	MAE	RMSE
B1	10 230 (25)	14 216 (33)	10 254	14 936	22 472	27 061
B2	–	–	11 341	15 652	14 409	18 637
M1	9 145 (138)	12 565 (154)	9 832	13 901	15 202	20 283
M2	8 293 (121)	11 736 (159)	9 258	13 413	15 218	19 917
S1	–	–	9 657	13 767	16 738	21 052
S2	–	–	10 057	14 027	12 545	15 901

(a) no tiene sentido para B2, S1 y S2 porque esos modelos son la historia reciente ordenada. B2 no se ajusta (copia el valor de la semana anterior), así que no hay nada que entrenar en cuatro folds. Si se aplicara de todos modos, el "mismo día más reciente" podría estar después del día que se predice. S1 y S2 son recursiones sobre filas consecutivas, y una partición al azar deja huecos en la serie y pondría a predecir un día de mayo con un modelo que ya vio junio. Eso es interpolar y no pronosticar. B1, M1 y M2 sí se pueden ajustar sobre filas sueltas, porque sus predictores (indicadoras, t, rezagos ya calculados) están en cada fila.

(b) se acerca más a (c) que (a). Para los tres modelos que tienen las dos, (a) da el error más bajo: el MAE de M2 es 8 293 en (a), 9 258 en (b) y 15 218 en (c). Pero ninguna se acerca de verdad. El error de prueba es entre un 25 % y un 120 % mayor que lo que estimaron, y además las dos ordenan mal los modelos. Dentro del entrenamiento, el origen móvil pone a M2 primero, S1 segundo y a B2 último, y en la prueba gana S2 y B2 queda segundo. Dentro del entrenamiento (con el nivel casi

plano de mayo a agosto) un modelo que se ajusta lento a los cambios no pierde nada. En la prueba el nivel cambió, y eso cambió quién gana.

Inciso 5.3: quién gana en prueba y por qué



Figura 10: Pronósticos del origen móvil semanal contra la venta real del 3 de octubre al 8 de diciembre de 2011 (en gris). Arriba los tres modelos de referencia, abajo M2 y los dos SARIMA.

Gana S2, con MAE de £12 545 y RMSE de £15 901, seguido de B2. Lo que los separa del resto es el nivel. La venta media de los días abiertos del entrenamiento fue £27 632 y la de la prueba £49 768, y de mes a mes pasó de £26 800 en agosto a £38 900 en septiembre, £40 800 en octubre, £54 900 en noviembre y £58 700 en diciembre. El sesgo medio en prueba (pronóstico menos real) lo resume:

	B1	B2	M1	M2	S1	S2
Sesgo medio (£)	−20 530	−2 743	−13 756	−12 902	−14 227	−1 187

B1, M1, M2 y S1 están anclados al pasado: B1 a la media del año, M1 a una recta ajustada sobre un año casi plano, M2 a coeficientes que pesan poco los rezagos, y S1 tira hacia su media de largo plazo, que en cada reajuste sigue muy por debajo del nivel de otoño. Los cuatro reaccionan tarde a la subida y se quedan cortos por £13 000 a £20 000 diarios en promedio. En la figura 10 se ve que las líneas de abajo, salvo la verde, van casi siempre por debajo de la gris. S2 y B2 siguen el nivel más

reciente y no tienen ese sesgo. B2 lo sigue copiando, y por eso copia también los picos sueltos: el lunes 14 de noviembre vendió £110 000 y B2 pronosticó £110 000 para el lunes 21. S2 lo sigue suavizando ($1 + \theta = 0.086$), con el patrón semanal aparte, y por eso tiene menos ruido que B2.

La respuesta a 4.4 dice lo mismo desde los residuos. S2 era el único modelo que dejaba ruido blanco, es decir, el único que había capturado toda la estructura de la serie, incluido el nivel que se mueve. S1 dejaba autocorrelación en los rezagos 5, 6 y 12, y esa es información sobre el futuro que el modelo no aprovecha. Cuando el nivel cambió en otoño, lo que S1 no había capturado en el entrenamiento se convirtió en error de pronóstico.

Inciso 5.4: la trampa

Tabla 13: M2 con y sin la media móvil centrada de 7 días como predictor.

	(a) CV aleatoria		(b) Origen móvil	
Modelo	MAE	RMSE	MAE	RMSE
M2	8 293 (121)	11 736 (159)	9 258	13 413
M2 + media móvil	7 416 (78)	10 028 (96)	8 378	11 363

Se ve mejor: baja el MAE un 10 % con las dos validaciones y el RMSE un 15 %. Es una mejora falsa. La media móvil centrada del día t es el promedio de $y_{t-3}, \ldots, y_{t+3}$. Contiene la propia venta que se quiere pronosticar y la de los tres días siguientes, así que es un predictor ilegal: le pasa al modelo una séptima parte de la respuesta, más el nivel de los días que vienen después.

El origen móvil no lo detecta porque la media móvil se calculó una sola vez sobre toda la serie y quedó guardada como una columna más. El origen móvil controla qué filas se usan para ajustar y cuáles para evaluar, pero no qué información trae cada predictor. Si la columna ya tiene el futuro adentro, cortar las filas en el origen no la limpia. La fuga está en cómo se construyó la variable, no en cómo se partieron los datos.

Y (c) no se puede calcular sin hacer trampa. El domingo del origen, la media móvil del lunes siguiente necesita las ventas de viernes a jueves, y cuatro de esas (lunes a jueves) aún no han ocurrido. Para el 6, 7 y 8 de diciembre ni siquiera existe, porque necesita días posteriores al final de los datos. Haciendo la trampa, en los 55 días de prueba donde existe, M2 con la media móvil tendría un MAE de £9 113 contra £15 043 del M2 honesto. Es el mejor número de todo el trabajo, y no se puede reproducir en la vida real.

Inciso 5.5: por qué todo se queda corto

Hay dos causas. La primera viene de cómo se partieron los datos. La validación cruzada aleatoria pone en el entrenamiento los días vecinos del día evaluado, antes y después. Con una serie autocorrelacionada eso es interpolar: el martes se adivina mejor si se conoce el lunes y el miércoles. Por eso (a) da siempre el error más bajo. Esta causa se arregla con una mejor validación, respetando el tiempo como hace el origen móvil, y por eso (b) se acerca más a (c).

La segunda es que la serie cambió. La prueba cae en la temporada navideña, con un nivel 1.8 veces el del entrenamiento, y ninguna partición del entrenamiento contiene un periodo así. Enero a septiembre no tienen un otoño del cual aprender. Esta causa no se arregla validando mejor, porque ninguna validación hecha con datos de un régimen puede medir el error en un régimen que nunca vio. Solo se arregla con datos que contengan ese régimen, es decir, con el otoño de otros años.

Con un solo año no se puede estimar la estacionalidad anual. Para separar un efecto estacional de una tendencia hace falta ver el ciclo al menos dos veces. Aquí cada mes aparece una sola vez, y la

subida de septiembre a diciembre de 2011 podría ser temporada navideña, crecimiento del negocio o las dos cosas. Diciembre de 2010, que también fue alto (£37 900 diarios), sugiere que es temporada, pero es un solo dato. Por eso, y por la regla de FPP2 de tener al menos dos periodos completos, los modelos de esta tarea solo tienen estacionalidad semanal.

Parte 6: detrás de la serie hay clientes: análisis RFM

Inciso 6.1: R, F y M al 1 de octubre

Con los datos limpios que tienen `CustomerID` y solo las transacciones anteriores al 1 de octubre de 2011, hay 3 615 clientes con al menos una factura de venta. La recencia es el número de días entre la fecha de su última factura de venta y el 1 de octubre (1 para quien compró el 30 de septiembre). La frecuencia es el número de facturas de venta distintas, sin contar las cancelaciones, y el monto es la venta neta, con las cancelaciones restando. Otros 43 clientes solo tienen cancelaciones antes del corte (devoluciones de pedidos anteriores a diciembre de 2010), no tienen ninguna compra que dé recencia o frecuencia, y no entran.

13 clientes tienen $M \leq 0$: 6 con monto exactamente cero y 7 negativo, que suman $-$£1 981. Son clientes que devolvieron todo lo que compraron o más, porque devolvieron mercancía comprada antes de que empezaran los datos. Entre ellos está el 12346 del inciso 1.4, con $F = 1$ y $M = 0$. Se quedan en el análisis, porque 6.2 los incluye en el orden, y caen en el puntaje de monto más bajo, que es lo que les corresponde porque no han dejado ingreso. Lo que no se hace es interpretar su M como un monto de compra.

No se puede usar nada posterior al 1 de octubre porque en 6.3 la variable que se quiere predecir es si el cliente compró después de esa fecha. Si una compra de noviembre entrara en la recencia, el cliente aparecería como reciente justo porque compró. Sería el predictor ilegal de 5.4 otra vez, con la respuesta metida en el predictor, y el AUC saldría inflado.

Inciso 6.2: puntajes por quintiles

El problema con F es que hay demasiados empates. El 40.1 % de los clientes tiene $F = 1$ y el 19.1 % $F = 2$, así que los cuantiles del 20 % y del 40 % valen los dos 1, y `pd.qcut(F, 5)` falla con "Bin edges must be unique". No hay forma de partir en cinco grupos de igual tamaño a clientes que tienen exactamente el mismo valor.

Con el desempate del enunciado (orden por `CustomerID`, permutación con `default_rng(2026)` y `qcut` sobre `rank(method='first')`) cada puntaje queda con 723 clientes. Los 1 449 clientes con $F = 1$ se reparten en 723 con puntaje 1, 723 con puntaje 2 y 3 con puntaje 3. El mismo procedimiento se aplicó a R y a M para que las tres dimensiones tengan puntajes reproducibles. Lo que esto implica es que dos clientes con la misma F pueden tener puntajes distintos por sorteo, y esa diferencia no dice nada del cliente. Con otra semilla se intercambian. La tabla 14 lo confirma: los puntajes 1 y 2 de frecuencia, que son todos clientes con $F = 1$, compran en proporciones casi iguales (0.329 y 0.310), y el 2 hasta queda un poco por debajo.

Inciso 6.3: ¿quién vuelve a comprar?

De los 3 615 clientes, 1 835 (el 50.8 %) hicieron al menos una compra entre el 1 de octubre y el 8 de diciembre.

Tabla 14: Fracción de clientes que compró entre el 1 de octubre y el 8 de diciembre, por puntaje (5 es el mejor).

Puntaje	1	2	3	4	5	5 menos 1
Recencia	0.277	0.385	0.550	0.664	0.663	0.386
Frecuencia	0.329	0.310	0.450	0.593	0.856	0.527
Monto	0.295	0.373	0.455	0.610	0.805	0.510

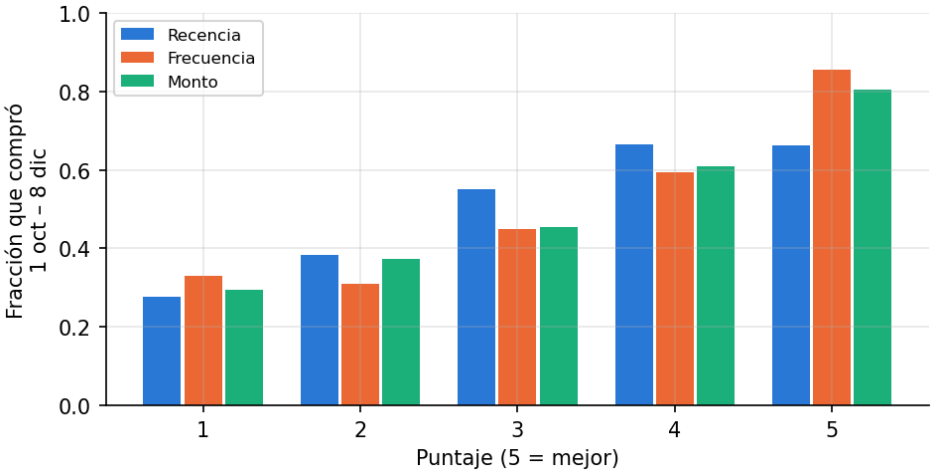


Figura 11: La misma información de la tabla 14.

Tabla 15: AUC de cada dimensión como clasificador de compra$_i$. El AUC es la probabilidad de que un comprador tenga un valor más alto que un no comprador, y se calcula con la fórmula de Mann–Whitney a partir de los rangos.

Variable	AUC
Recencia ($-R$, crudo)	0.6720
Frecuencia (F, crudo)	0.7201
Monto (M, crudo)	0.7086
Suma de los tres puntajes	0.7338

La frecuencia es la que mejor separa. Su puntaje 5 compra en un 86 %, casi tres veces que el puntaje 1, y tiene el AUC individual más alto (0.720). El monto está cerca (0.709), y tiene sentido, porque quien compra muchas veces suele acumular mucho monto. La recencia es la más débil (0.672) y se aplana arriba: los puntajes 4 y 5 compran igual (0.664 y 0.663). Con un periodo de compra de diez semanas, haber comprado hace 10 días o hace 30 da lo mismo. Lo que separa es haber comprado en los últimos meses o no. La suma de los tres puntajes da el mejor AUC (0.734), aunque solo un poco más que F sola, porque las tres dimensiones repiten buena parte de la misma información.

Incisos 6.4 y 6.5: campeones y clientes nuevos

Tabla 16: Reparto de la venta neta del 1 de octubre al 8 de diciembre entre todos los clientes con `CustomerID`, incluidos los nuevos.

Grupo	N.ž de clientes	Fracción de clientes	Venta oct–dic (£)	Fracción de la venta
Campeones (4 o 5 en R, F y M)	777	0.215	1 278 410	0.533
Resto de clientes con historia	2838	0.785	744 419	0.310
Clientes nuevos	723	–	377 860	0.157
Total con `CustomerID`			2 400 689	1.000

6.4. Los campeones son 777 clientes, el 21.5 % de los clientes de 6.1, y generaron el 53.3 % de la venta neta de octubre a diciembre de todos los clientes con `CustomerID`. El 81.6 % de ellos volvió a comprar. Es la regla de Pareto que justifica el RFM: una quinta parte de los clientes sostiene la mitad de la venta.

6.5. Los clientes nuevos, que no tienen ninguna factura de venta antes del 1 de octubre, son 723 y generaron el 15.7 % de esa venta, £377 860. Ningún análisis RFM ni ningún modelo cliente por cliente puede pronosticar esa venta, porque esos clientes no existen en la tabla del 1 de octubre. No tienen R, F ni M, y no hay ninguna fila a la que asignarles una probabilidad de compra. Un pronóstico bottom-up, que pronostica cada cliente conocido y suma, deja fuera por construcción ese 15.7 %. Si además se arma solo con clientes identificados, deja fuera también la venta sin `CustomerID`, que en el mismo periodo es el 17.2 % del total (£497 371 de £2 898 060). Para la venta total, los nuevos son el 13.0 %.

El pronóstico de la Parte 5 es top-down: pronostica el total, y el total ya incluye cada día la venta de los clientes que llegaron por primera vez, con o sin `CustomerID`. No sabe quiénes son, pero sí sabe cuánto suelen aportar en conjunto, porque eso está en la historia de la serie. Por eso el top-down puede ver a los clientes nuevos y el bottom-up no. Para el proyecto del curso, que compara los dos enfoques, el bottom-up tendrá un sesgo hacia abajo de al menos la venta de los clientes que todavía no existen, y en una tienda que crece en otoño ese sesgo crece justo cuando más importa, igual que el sesgo de los modelos anclados al pasado en la Parte 5. La única forma de corregirlo es agregarle al bottom-up un modelo aparte para la llegada de clientes nuevos, que es un pronóstico agregado.

Referencias

- D. Chen. Online Retail [conjunto de datos]. UCI Machine Learning Repository, 2015. `https://archive.ics.uci.edu/dataset/352/online+retail`
- D. Chen, S. L. Sain y K. Guo. “Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining”. Journal of Database Marketing & Customer Strategy Management 19.3, 2012, pp. 197–208.
- R. J. Hyndman y G. Athanasopoulos. Forecasting: Principles and Practice. 2.ª ed. OTexts, Melbourne, 2018. `https://otexts.com/fpp2/`. Capítulos 2, 3, 6, 8, 10 y 12.
- R. S. Tsay. Analysis of Financial Time Series. 2.ª ed. Wiley, 2005. Capítulo 2, secciones 2.1 a 2.8.
- G. E. P. Box, G. M. Jenkins, G. C. Reinsel y G. M. Ljung. Time Series Analysis: Forecasting and Control. 5.ª ed. Wiley, 2015. Capítulo 9 (el modelo de aerolínea).

- G. M. Ljung y G. E. P. Box. “On a measure of lack of fit in time series models”. Biometrika 65.2, 1978, pp. 297–303.
- F. H. C. Marriott y J. A. Pope. “Bias in the estimation of autocorrelations”. Biometrika 41.3/4, 1954, pp. 390–402.
- GOV.UK. UK bank holidays. `https://www.gov.uk/bank-holidays`
- S. Seabold y J. Perktold. “Statsmodels: Econometric and statistical modeling with Python”. Proceedings of the 9th Python in Science Conference, 2010.